

IMPLEMENTASI K-MEANS CLUSTERING UNTUK SEGMENTASI PRODUK E-COMMERCE BERBASIS DATA MINING PADA DATASET AMAZON

Latanza Akbar Fadilah¹, Zakii Ramadhan², Laila Nazmi³, Khania Ramadhani⁴, Nurhafifah Matondang⁵

Program Studi D-III Sistem Informasi / Fakultas Ilmu Komputer,
Universitas Pembangunan Nasional Veteran Jakarta

Jl. RS. Fatmawati Raya, Pd. Labu, Kec. Cilandak, Kota Depok, Jawa Barat

2410501004@mahasiswa.upnvj.ac.id¹, 2410501021@mahasiswa.upnvj.ac.id²,

2410501024@mahasiswa.upnvj.ac.id³, 2410501027@mahasiswa.upnvj.ac.id⁴

nurhafifahmatondang@upnvj.ac.id⁵

Abstrak. Penelitian ini mengimplementasikan algoritma K-Means Clustering untuk melakukan segmentasi produk pada dataset e-commerce Amazon menggunakan software Orange Data Mining. Dataset terdiri dari 1.465 data produk dengan fitur harga asli, harga diskon, persentase diskon, dan jumlah rating pelanggan. Tahapan analisis meliputi preprocessing menggunakan Widget Formula, Select Columns, Impute, dan Normalize Features, dilanjutkan penerapan K-Means. Evaluasi Silhouette Score menentukan kluster optimal $k=2$ dengan skor 0,556 (Moderate Structure). Hasil klusterisasi menghasilkan tiga profil produk: Cluster C1 (Premium/Flagship), C2 (Fast-Moving/Mass Market), dan C3 (Underperforming/Risk). Temuan ini memberikan landasan Business Intelligence untuk pengambilan keputusan strategis manajemen portofolio produk.

Kata Kunci : Data Mining, K-Means Clustering, Orange Data Mining, E-Commerce Amazon, Silhouette Score, Business Intelligence

1 Pendahuluan

Perkembangan industri e-commerce di era digital telah menghasilkan akumulasi data transaksi produk dalam jumlah yang sangat masif. Perusahaan platform seperti Amazon mengoperasikan katalog produk yang mencapai jutaan item dengan variasi harga, diskon, dan performa ulasan pelanggan yang sangat beragam. Dalam konteks persaingan bisnis yang semakin intens, kemampuan manajemen untuk memahami karakteristik portofolio produk secara ilmiah dan berbasis data (data-driven) menjadi faktor penentu keunggulan kompetitif yang signifikan. Permasalahan mendasar yang dihadapi oleh pengelola platform e-commerce adalah ketidakmampuan untuk mengklasifikasikan produk secara sistematis berdasarkan pola karakteristik yang tersembunyi di balik data mentah. Tanpa segmentasi yang tepat, alokasi sumber daya pemasaran, strategi penetapan harga, dan manajemen inventaris berpotensi berjalan secara tidak efisien, sehingga berdampak negatif terhadap profitabilitas perusahaan secara keseluruhan.

Data mining, sebagai cabang ilmu yang berfokus pada ekstraksi pengetahuan dari data bervolume besar, menawarkan solusi melalui pendekatan algoritma pembelajaran mesin tanpa pengawasan (unsupervised machine learning). Salah satu algoritma yang paling banyak diaplikasikan dalam konteks klusterisasi data adalah K-Means Clustering, yang bekerja dengan cara mengelompokkan objek data ke dalam k kelompok berdasarkan kemiripan karakteristik atau kedekatan jarak (Han, Kamber & Pei, 2012) [2].

Penelitian ini bertujuan untuk: (1) mengimplementasikan algoritma K-Means Clustering pada dataset produk Amazon menggunakan software Orange Data Mining; (2) melakukan segmentasi produk berdasarkan variabel harga asli, harga diskon, persentase diskon, dan jumlah rating pelanggan; serta (3) menginterpretasikan hasil klusterisasi sebagai wawasan bisnis strategis (Business Intelligence) yang dapat digunakan sebagai dasar rekomendasi manajemen portofolio produk.

Manfaat penelitian ini mencakup aspek teoritis dan praktis. Secara teoritis, penelitian ini berkontribusi pada pengembangan literatur data mining dalam konteks e-commerce domestik dan internasional. Secara praktis, hasil segmentasi dapat menjadi acuan bagi manajer produk dan tim pemasaran dalam merancang strategi yang lebih terarah dan efisien berdasarkan profil setiap kelompok produk.

Penelitian ini bertujuan mengimplementasikan K-Means Clustering pada dataset Amazon menggunakan Orange Data Mining, difokuskan pada pengelompokan produk berdasarkan karakteristik harga asli, harga diskon, persentase diskon, dan jumlah rating pelanggan untuk menghasilkan segmentasi yang bernilai strategis bagi manajemen portofolio produk.

2 Tinjauan Pustaka

2.1 Data Mining

Data mining merupakan proses ekstraksi pengetahuan dari dataset berukuran besar melalui penggunaan teknik statistik, machine learning, dan kecerdasan buatan [3]. Tujuan utamanya adalah menemukan pola, korelasi, anomali, dan wawasan bermakna yang tersembunyi di dalam data mentah. Proses data mining umumnya mengikuti kerangka CRISP-DM yang mencakup pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan penyebaran.

2.2 K-Means Clustering

K-Means Clustering adalah algoritma partisi berbasis centroid yang mengelompokkan data ke dalam k buah kluster [4]. Algoritma ini bekerja secara iteratif: (1) menginisialisasi k centroid secara acak atau menggunakan metode KMeans++; (2) menugaskan setiap titik data ke centroid terdekat berdasarkan jarak Euclidean; (3) memperbarui posisi centroid dengan menghitung rata-rata semua titik dalam kluster; dan (4) mengulang langkah 2-3 hingga konvergensi. Kualitas hasil klusterisasi dievaluasi menggunakan Silhouette Score, di mana nilai mendekati 1,0 menunjukkan pemisahan kluster yang sangat baik, nilai 0,5 menunjukkan struktur moderat, dan nilai mendekati 0 menunjukkan kluster yang tumpang tindih [5].

2.3 Orange Data Mining

Orange Data Mining adalah perangkat lunak open-source berbasis Python yang menyediakan antarmuka pemrograman visual untuk analisis data dan machine learning [6]. Orange memungkinkan pengguna membangun alur kerja analisis melalui komponen widget yang dapat disambungkan secara intuitif tanpa penulisan kode secara langsung. Widget-widget yang tersedia mencakup pemrosesan data, transformasi fitur, pemodelan, evaluasi, dan visualisasi.

2.4 Business Intelligence (BI)

Business Intelligence (BI) merujuk pada serangkaian proses, teknologi, dan alat yang digunakan untuk mengubah data mentah menjadi informasi bermakna guna mendukung pengambilan keputusan bisnis [7]. Segmentasi berbasis data mining merupakan salah satu teknik BI yang memungkinkan manajemen memahami struktur portofolio produk dan merancang strategi yang dipersonalisasi untuk setiap segmen.


3 Metodologi Penelitian

3.1 Sumber Dataset

Dataset yang digunakan dalam penelitian ini adalah dataset e-commerce Amazon (amazon.csv) yang berisi data produk dengan total 1.465 baris rekaman. Dataset mencakup atribut-atribut seperti nama produk, kategori, harga asli (actual_price), harga setelah diskon (discounted_price), persentase diskon (discount_percentage), rating bintang, dan jumlah ulasan pelanggan (rating_count). Kolom-kolom numerik tersebut tersimpan dalam format teks bersimbol mata uang India (₹), koma (,), dan persen (%), sehingga memerlukan tahap konversi sebelum dapat diproses oleh algoritma.

3.2 Alur Kerja (Workflow)

Alur kerja analisis dirancang secara linier dan modular pada platform Orange Data Mining. Data mentah diunggah melalui widget File, kemudian melewati proses pembersihan karakter non-numerik pada widget Formula (Feature Constructor), diikuti penyeleksian kolom fungsional pada widget Select Columns. Selanjutnya, data yang kosong ditangani menggunakan widget Impute, dinormalisasi menggunakan widget Preprocess, sebelum akhirnya diproses oleh algoritma K-Means Clustering dan divisualisasikan melalui widget Scatter Plot.




Gambar 1. Alur Kerja (Workflow) Analisis K-Means pada Orange Data Mining

3.3 Preprocessing Data

Tahap preprocessing merupakan fondasi keberhasilan analisis klusterisasi. Empat sub-tahap preprocessing dilakukan secara berurutan sebagai berikut.

a. Widget Formula (Feature Constructor)


Untuk menghindari kegagalan konversi tipe data (string-to-float error) akibat karakter simbol ₹, tanda koma (,), dan persen (%), diimplementasikan rumus logika bersyarat (conditional expressions) yang menghasilkan tiga kolom numerik baru: (1) `harga_asli_angka` — nilai harga asli setelah pembuangan simbol ₹ dan koma; (2) `harga_diskon_angka` — nilai harga diskon dalam format desimal murni; dan (3) `persen_diskon_angka` — proporsi diskon tanpa simbol %.



Gambar 2. Konfigurasi Widget Formula untuk Konversi Kolom Numerik

b. Widget Select Columns


Pada analisis klusterisasi (unsupervised learning), variabel target tidak dipergunakan. Empat kolom numerik fungsional (`rating_count`, `harga_asli_angka`, `harga_diskon_angka`, `persen_diskon_angka`) ditetapkan sebagai Features, sedangkan kolom non-numerik seperti nama produk, kategori, dan ID produk dipindahkan ke kotak Meta Attributes agar tidak ikut memengaruhi perhitungan jarak algoritma.



Gambar 3. Konfigurasi Widget Select Columns

c. Widget Impute (Penanganan Missing Values)


Dataset e-commerce sering kali memiliki data tidak lengkap (kosong/NA) pada baris tertentu, misalnya produk yang belum memiliki rating. Jika tidak ditangani, algoritma K-Means akan mengalami kegagalan komputasi. Widget Impute dengan metode Average/Most-frequent digunakan untuk menambal nilai kosong menggunakan nilai rata-rata dari seluruh produk. Langkah ini menjaga integritas dan jumlah baris data agar tidak ada informasi produk yang terbuang.



Gambar 4. Konfigurasi Widget Impute dengan Metode Average/Most-frequence

d. Widget Preprocess (Normalisasi Fitur)

Dikarenakan variabel harga memiliki nilai ribuan sedangkan variabel rating hanya bernilai satuan (1–5), algoritma K-Means tanpa normalisasi akan secara bias mendominasi klusterisasi berdasarkan variabel harga saja. Opsi Normalize Features (Standardize to $\mu=0$, $\sigma^2=1$) pada widget Preprocess digunakan untuk menyetarakan bobot seluruh fitur ke dalam rentang skala yang seimbang, sehingga setiap dimensi memberikan kontribusi proporsional terhadap perhitungan jarak Euclidean.



Gambar 5. Konfigurasi Widget Preprocess

3.4 Konfigurasi Algoritma K-Means

Algoritma K-Means dikonfigurasi dengan parameter sebagai berikut: (1) rentang jumlah kluster k dari 2 hingga 5 untuk memungkinkan pemilihan otomatis berdasarkan Silhouette Score; (2) metode inisialisasi KMeans++ untuk mendapatkan centroid awal yang lebih representatif; (3) 10 kali re-run untuk menghindari konvergensi pada local minimum; dan (4) maksimum 300 iterasi per eksekusi. Normalisasi kolom juga diaktifkan pada widget K-Means sebagai lapisan preprocessing tambahan.


4 Hasil dan Pembahasan

4.1 Evaluasi Silhouette Score

Berdasarkan hasil komputasi optimasi jumlah kluster menggunakan metode Silhouette Score pada rentang $k=2$ hingga $k=5$, algoritma K-Means menetapkan jumlah kluster optimal untuk dataset e-commerce Amazon ini. Tabel 1 merangkum nilai Silhouette Score untuk setiap konfigurasi k yang diujikan.

Tabel 1. Hasil Evaluasi Silhouette Score

Jumlah Kluster (k)	Silhouette Score
2	0.556
3	0.264
4	0.264
5	0.176




Gambar 6. Hasil Komputasi Silhouette Score

Nilai Silhouette Score tertinggi yang dicapai adalah sebesar 0,556 pada $k=2$. Angka ini menunjukkan bahwa struktur kluster sudah cukup terbentuk dengan baik (Moderate Structure) untuk dataset dunia nyata yang penuh dengan noise dan variabilitas tinggi. Nilai $k=3$ dan $k=4$ menghasilkan skor yang sama (0,264) dan signifikan lebih rendah, sedangkan $k=5$ memberikan skor terendah (0,167), mengindikasikan bahwa penambahan jumlah kluster justru memperburuk kualitas pemisahan. Berdasarkan hasil ini, $k=2$ ditetapkan sebagai jumlah kluster optimal.

4.2 Visualisasi Scatter Plot

Melalui visualisasi multidimensi pada widget Scatter Plot dengan sumbu-x mewakili persen_diskon_angka dan sumbu-y mewakili rating, sebaran produk Amazon terbagi ke dalam dua kelompok kluster yang kontras berdasarkan warna. Perbedaan distribusi antar kluster terlihat jelas pada dimensi persentase diskon dan rating produk.



Gambar 7. Visualisasi Scatter Plot

4.3 Profil Klaster dan Implikasi Bisnis

Berdasarkan karakteristik dominan pada tiap-tiap kelompok yang diidentifikasi dari visualisasi dan statistik deskriptif klaster, profil produk (Cluster Profiling) beserta rekomendasi strategis Business Intelligence dijabarkan dalam Tabel 2.

Tabel 2. Profil Klaster dan Rekomendasi Strategis Business Intelligence

Identitas Klaster	Karakteristik Utama Fitur	Label / Profil Produk	Rekomendasi Strategis BI
Cluster C1	Harga Asli Tinggi, Diskon Rendah-Sedang, Rating Bintang Stabil Tinggi	Premium / Flagship Products	Pertahankan margin keuntungan yang tinggi. Fokus pada kampanye branding eksklusif dan optimasi layanan purnajual untuk menjaga kepuasan pelanggan loyal.
Cluster C2	Harga Murah, Persentase Diskon Sangat Tinggi, Jumlah Rating / Volume Penjualan Masif.	Fast-Moving / Mass Market Products	Gunakan strategi penetrasi pasar. Jaga ketersediaan stok pasokan (inventory control) secara ketat karena produk ini menjadi pendorong utama arus perputaran kas (cash flow) perusahaan.

Cluster C1 (Premium/Flagship Products) dicirikan oleh harga asli yang tinggi, tingkat diskon rendah hingga sedang, serta rating bintang yang stabil pada angka tinggi. Kelompok ini merepresentasikan produk-produk unggulan yang memiliki loyalitas pelanggan tinggi. Rekomendasi BI untuk klaster ini adalah mempertahankan margin keuntungan yang tinggi, memfokuskan anggaran pemasaran pada kampanye branding eksklusif, serta mengoptimalkan layanan purnajual (after-sales service) guna menjaga kepuasan dan retensi pelanggan loyal.

Cluster C2 (Fast-Moving/Mass Market Products) dicirikan oleh harga yang relatif murah, persentase diskon yang sangat tinggi, dan jumlah rating atau volume penjualan yang masif. Kelompok ini merepresentasikan produk-produk penggerak utama pendapatan melalui volume transaksi. Rekomendasi BI untuk klaster ini adalah menerapkan strategi penetrasi pasar yang agresif, menjaga ketersediaan stok pasokan (inventory control) secara ketat, serta memanfaatkan data pola beli pelanggan untuk rekomendasi produk yang dipersonalisasi.

Implementasi algoritma K-Means pada dataset e-commerce Amazon ini membuktikan bahwa strategi penetapan harga dan pemberian diskon memiliki korelasi struktural terhadap volume ulasan dan performa penjualan produk di pasar. Segmentasi berbasis data mining memberikan landasan Business Intelligence yang kuat bagi manajemen untuk mendiversifikasi perlakuan pemasaran terhadap setiap kelompok produk guna mengoptimalkan profitabilitas retailsecaraberkelanjutan.

5 Penutup

5.1 Kesimpulan

Berdasarkan hasil eksperimen klusterisasi menggunakan algoritma K-Means pada dataset e-commerce Amazon yang diimplementasikan melalui Orange Data Mining, dapat ditarik kesimpulan sebagai berikut:

- a. Jumlah kluster optimal yang dihasilkan melalui optimasi Silhouette Score adalah $k=2$ dengan skor 0,556, yang mengindikasikan struktur kluster moderat yang cukup bermakna untuk dataset e-commerce dunia nyata yang sarat noise.
- b. Dua segmen produk yang teridentifikasi — Premium/Flagship Products (Cluster C1) dan Fast-Moving/Mass Market Products (Cluster C2) — memiliki karakteristik harga, diskon, dan volume rating yang berbeda secara signifikan, sehingga memerlukan pendekatan strategi pemasaran yang berbeda pula.
- c. Tahapan preprocessing yang komprehensif, khususnya konversi format data, penanganan missing values, dan normalisasi fitur, terbukti krusial untuk menghasilkan kluster yang berkualitas baik.

5.2 Saran

Berdasarkan keterbatasan penelitian ini, berikut saran yang diajukan untuk penelitian selanjutnya:

- a. Diharapkan penelitian selanjutnya dapat mengeksplorasi algoritma klusterisasi lain seperti DBSCAN atau Hierarchical Clustering sebagai pembanding untuk mengevaluasi apakah segmentasi yang berbeda dapat memberikan wawasan bisnis yang lebih granular.
- b. Fitur-fitur tambahan seperti kategori produk, sentimen ulasan teks, dan data temporal (tren penjualan per periode) dapat diintegrasikan untuk menghasilkan segmentasi yang lebih komprehensif dan representatif.
- c. Penelitian lanjutan dapat mengintegrasikan hasil segmentasi ini ke dalam sistem Business Intelligence yang terhubung dengan dashboard real-time untuk mendukung pengambilan keputusan operasional secara dinamis.

Referensi

- [1] Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann Publishers.
- [2] MacQueen, J. B. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *Proceedings of 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.
- [3] Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From Data Mining to Knowledge Discovery in Databases. *AI Magazine*, 17(3), 37–54.
- [4] Hartigan, J. A., & Wong, M. A. (1979). A K-Means Clustering Algorithm. *Applied Statistics*, 28(1), 100–108. doi: 10.2307/2346830.
- [5] Rousseeuw, P. J. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. doi: 10.1016/0377-0427(87)90125-7.
- [6] Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevár, T., Milutinovič, M., ... & Zupan, B. (2013). Orange: Data Mining Toolbox in Python. *Journal of Machine Learning Research*, 14, 2349–2353.
- [7] Negash, S. (2004). Business Intelligence. *Communications of the Association for Information Systems*, 13, 177–195.
- [8] Agrawal, R., & Srikant, R. (1994). Fast Algorithms for Mining Association Rules. *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, 487–499.
- [9] Tan, P. N., Steinbach, M., & Kumar, V. (2006). *Introduction to Data Mining*. Addison-Wesley.
- [10] Wu, X., Kumar, V., Quinlan, J. R., Ghosh, J., Yang, Q., Motoda, H., ... & Steinberg, D. (2008). Top 10 Algorithms in Data Mining. *Knowledge and Information Systems*, 14(1), 1–37.